Simulación Montecarlo de un sistema de inventarios

Taller 2 · Métodos Cuantitativos

Nombre Completo
Juan Andrés Young Hoyos
Código de estudiante: 1000337497



Medellín, 28 de octubre de 2026

Índice

1 Introducción **2**

1.1 Verificación del modelo 2

2 Parte A: análisis del modelo en Excel **2**

2.1 Construcción del libro 2

2.2 Pregunta 1: desempeño de la política recomendada 3

2.3 Pregunta 2: media y varianza teóricas de la demanda 3

2.4 Pregunta 3: comparación de políticas y criterio de selección 4

2.5 Pregunta 4: forma de los histogramas y origen de la variabilidad 5

2.6 Pregunta 5: $s \geq 7$ y $Q \geq 7$ implican cero ventas perdidas 6

2.7 Pregunta 6: efecto de aumentar Q con s fijo 7

3 Parte B: análisis del modelo en Python **7**

3.1 Pregunta 1: estadísticos, histogramas y comparación con Excel 8

3.2 Pregunta 2: sensibilidad a la semilla 9

3.3 Pregunta 3: rejilla amplia de políticas 9

3.4 Pregunta 4: ¿por qué la misma semilla para todas las políticas? 11

3.5 Pregunta 5: Excel frente a Python 12

4 Conclusiones **12**

5 Referencias **13**

1 | Introducción

Este documento presenta el análisis del Taller 2. Se simula un año completo (los 313 días hábiles de 2026, de lunes a sábado) de un sistema de inventarios con política (s, Q): al cierre de cada día, si el inventario final es estrictamente menor que s, se piden Q unidades, que llegan al inicio del siguiente día hábil. La demanda diaria es discreta entre 3 y 7 unidades y se estudian dos casos: uniforme discreta y empírica [3]. Cada experimento usa 100 réplicas independientes del año.

El modelo se construyó en dos herramientas que respetan exactamente los mismos supuestos y ecuaciones del enunciado:

- **Parte A (Excel):** libro con las hojas `Parametros`, `Uniforme`, `Empirica` y `Politicas`, con nombres definidos, una fila por día hábil y una tabla de datos de 100 réplicas (`=TABLA(;W2)`).
- **Parte B (Python):** programa `.py` organizado en funciones (bloques B1 a B8), con semilla fija 1000337497 y números aleatorios comunes para comparar políticas.

La política recomendada es $\boldsymbol{s = 7,\ Q = 15}$. Las secciones siguientes justifican esta elección con los resultados de ambas herramientas.

1.1 | Verificación del modelo

Con $s = 6$, $Q = 10$ y demandas fijas de 4, 7 y 5 unidades, el libro de Excel (escribiendo temporalmente esas demandas en `G6:G8`) y la función `simulate_year` de Python producen exactamente los valores del enunciado (tabla 1.1). Además, en ambas hojas `B318` muestra 31/12/2026, `A318` vale 313 y la suma de la columna `D` es 12 (12 cargos de costo fijo); la comprobación automática de la celda `U10` es correcta.

Tabla 1.1: Ejemplo de verificación ($s = 6$, $Q = 10$). Idéntico en Excel y en Python.

Día	Fecha	R	II	D	V	P	IF	Pedido	Utilidad del día
1	jue 01/01/2026	10	10	4	4	0	6	0	−$4.320.640
2	vie 02/01/2026	0	6	7	6	1	0	1	$4.079.760
3	sáb 03/01/2026	10	10	5	5	0	5	1	−$2.640.600

2 | Parte A: análisis del modelo en Excel

2.1 | Construcción del libro

- `Parametros`: los ocho parámetros en `B4:B11` con sus nombres definidos (`PuntoReorden`, `CantPedido`, `PrecioVenta`, `CostoUnitario`, `CostoPedido`, `CostoAlm`, `CostoFijo`, `AnioSim`) y la tabla `TablaEmpirica` (`E4:F8`) de la transformada inversa, cuya suma de probabilidades se verifica en `G9`.
- `Uniforme` y `Empirica`: columnas `A` a `R` con las fórmulas del enunciado (fila 6 = día 1; fila 7 copiada hasta la 318). La única diferencia es la columna `G`: `=ALEATORIO.ENTRE(3;7)` frente a `=BUSCARV(ALEATORIO();TablaEmpirica;2;VERDADERO)`, que implementa el método de la transformada inversa [2].

- Resumen de la réplica en `U6:U8` (más el inventario final del 31/12 en `U9`), tabla de datos `W6:AA106` con celda de entrada vacía `W2`, estadísticos en `AC5:AC8` y histograma de 10 clases de igual ancho en `AB16:AF26` con su gráfico de columnas (ancho de intervalo 0 %).
- `Politicas`: 9 combinaciones (s, Q) por cada caso de demanda, registradas como valores.

2.2 | Pregunta 1: desempeño de la política recomendada

Tabla 2.1 resume las 100 réplicas guardadas en el libro para $s = 7$, $Q = 15$.

Tabla 2.1: Estadísticos de la política recomendada en Excel (100 réplicas).

Estadístico	Demanda uniforme	Demanda empírica
Ganancia promedio ($\bar{G}$)	\$102.985.919	\$102.872.550
Desviación estándar (S_G, `DESVEST.M`)	\$3.147.848	\$3.148.471
Error estándar de la media ($S_G/\sqrt{100}$)	\$314.785	\$314.847
Probabilidad de ventas perdidas ($\hat{p}_{\text{perdida}}$)	0,0000	0,0000
Ventas perdidas promedio (unidades/día)	0,0000	0,0000

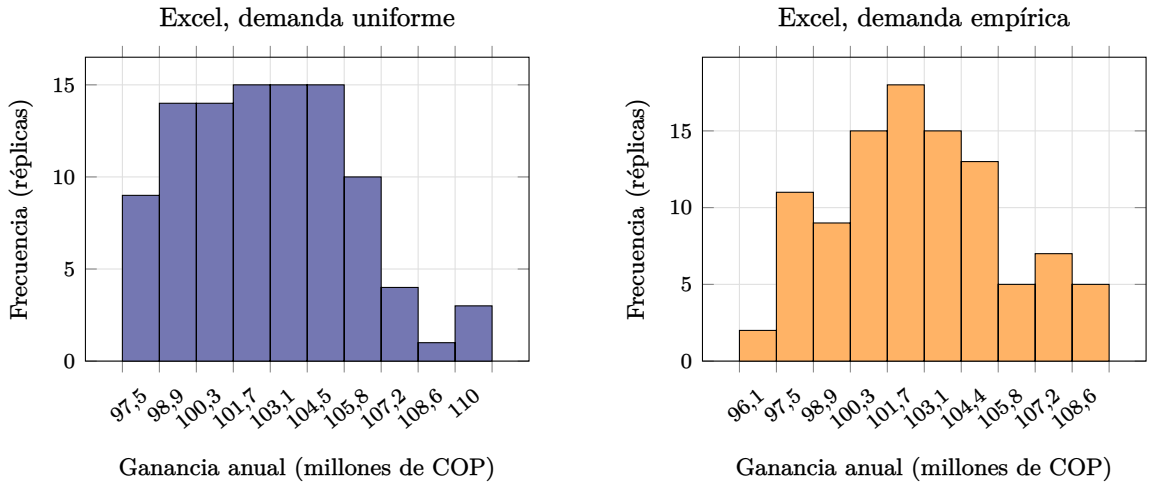


Figura 2.1: Histogramas de la ganancia anual en Excel (10 clases de igual ancho entre el mínimo y el máximo; las frecuencias suman 100 en ambos casos).

Justificación. Con $s = 7$ y $Q = 15$ no hubo ningún día con faltantes en ninguna de las 200 réplicas (313 días cada una), lo que coincide con el resultado teórico de la pregunta 5. La ganancia anual promedio está alrededor de \$103 millones en ambos casos, con una desviación estándar cercana a \$3 millones (aproximadamente 3 % de la media). El error estándar de la media, cercano a \$0,3 millones, indica que la ganancia esperada se estima con una precisión de aproximadamente ±\$0,6 millones (intervalo de confianza del 95 %).

2.3 | Pregunta 2: media y varianza teóricas de la demanda

Para una demanda discreta D con valores d y probabilidades $p(d)$: $E[D] = \sum_d d\,p(d)$ y $\text{Var}[D] = \sum_d (d - E[D])^2 p(d)$.

- **Uniforme:** $E[D] = 0{,}2\,(3+4+5+6+7) = 5$ y $\mathrm{Var}[D] = 0{,}2\,(4+1+0+1+4) = 2$ (equivale a $(k^2-1)/12$ con $k = 5$ valores); desviación estándar $\sqrt{2} \approx 1{,}414$.
- **Empírica:** $E[D] = 3(0{,}20) + 4(0{,}05) + 5(0{,}40) + 6(0{,}25) + 7(0{,}10) = 5$ y $\mathrm{Var}[D] = 4(0{,}20) + 1(0{,}05) + 0(0{,}40) + 1(0{,}25) + 4(0{,}10) = 1{,}5$; desviación estándar $\approx 1{,}225$.

Estos valores también se calculan con fórmulas en `Parametros!A21:D23`.

Parecido. Ambas distribuciones tienen el mismo soporte (3 a 7) y la misma media, 5 unidades por día. Por eso, en promedio, se demandan $5 \times 313 = 1565$ unidades al año en ambos casos y los ingresos esperados son prácticamente iguales.

Diferencia. La empírica tiene 25 % menos varianza: concentra el 40 % de la probabilidad en 5 y asigna solo 0,10 a la demanda máxima de 7, frente a 0,20 en la uniforme.

Efecto en ventas perdidas y ganancia. Con $s \geq 7$ no hay faltantes en ninguno de los dos casos (pregunta 5), así que la diferencia no se manifiesta en la política recomendada. Con $s < 7$ sí aparece. Por ejemplo, con $s = 6$ solo se pierde venta cuando el día empieza con exactamente 6 unidades y llega una demanda de 7; como $P(D = 7)$ es el doble en la uniforme, la probabilidad de faltante es aproximadamente el doble (hoja `Politicas`, tabla 2.2). En ganancia promedio las diferencias entre casos son pequeñas y del orden del error de Montecarlo, porque ambas demandas tienen la misma media. La menor varianza de la empírica se nota en las ventas perdidas, no en el ingreso esperado.

2.4 | Pregunta 3: comparación de políticas y criterio de selección

Tabla 2.2: Hoja `Politicas`: 9 políticas por caso de demanda, 100 réplicas cada una (resaltada la recomendada).

Demanda	s	Q	Ganancia promedio	Desv. estándar	Prob. pérdida	Perdidas/día
Uniforme	5	10	\$101.939.216	\$2.645.893	0,0627	0,0820
Uniforme	5	15	\$103.838.673	\$3.247.954	0,0410	0,0555
Uniforme	6	10	\$102.862.394	\$2.450.472	0,0205	0,0205
Uniforme	6	15	\$103.908.688	\$3.692.465	0,0131	0,0131
Uniforme	7	10	\$103.142.580	\$2.850.778	0,0000	0,0000
Uniforme	7	15	\$102.985.919	\$3.147.848	0,0000	0,0000
Uniforme	7	20	\$104.149.102	\$4.360.111	0,0000	0,0000
Uniforme	7	30	\$99.256.794	\$5.497.943	0,0000	0,0000
Uniforme	8	15	\$102.556.946	\$3.230.260	0,0000	0,0000
Empírica	5	10	\$102.317.104	\$2.590.491	0,0490	0,0597
Empírica	5	15	\$103.825.750	\$2.999.851	0,0312	0,0376
Empírica	6	10	\$102.845.517	\$2.387.694	0,0097	0,0097
Empírica	6	15	\$102.990.297	\$3.122.364	0,0056	0,0056
Empírica	7	10	\$102.845.421	\$2.168.174	0,0000	0,0000
Empírica	7	15	\$102.872.550	\$3.148.471	0,0000	0,0000
Empírica	7	20	\$103.232.336	\$3.875.958	0,0000	0,0000
Empírica	7	30	\$101.183.328	\$5.518.996	0,0000	0,0000
Empírica	8	15	\$102.602.372	\$3.265.082	0,0000	0,0000

Criterio explícito, aplicado en orden:

1. **Nivel de servicio:** cero ventas perdidas con ambas demandas. Una venta perdida significa un cliente insatisfecho; la pregunta 5 demuestra que $s \geq 7$ y $Q \geq 7$ lo garantizan sin importar la secuencia de demandas.

2. **Ganancia:** entre las políticas con servicio completo, la de mayor ganancia promedio considerando los dos casos de demanda (promedio de ambos).

3. **Riesgo:** si las diferencias de ganancia son menores que el error de Montecarlo, se prefiere la de menor desviación estándar y la que respalde la teoría (pregunta 6).

Tabla 2.3: Políticas con cero ventas perdidas en ambos casos, ordenadas por ganancia promedio conjunta.

s	Q	Uniforme	Empírica	Promedio de ambos
7	20	\$104.149.102	\$103.232.336	\$103.690.719
7	10	\$103.142.580	\$102.845.421	\$102.994.001
7	15	\$102.985.919	\$102.872.550	\$102.929.235
8	15	\$102.556.946	\$102.602.372	\$102.579.659
7	30	\$99.256.794	\$101.183.328	\$100.220.061

En esta corrida de Excel, la política de servicio completo con mayor ganancia conjunta es $s = 7$, $Q = 20$ (tabla 2.3), \$761.485 por encima de $s = 7$, $Q = 15$. Esa diferencia es menor que dos errores estándar (\$890.434), es decir, compatible con el azar. Por el criterio 3 se mantiene $Q = 15$: tiene menor desviación estándar (\$3.147.848 frente a \$4.360.111 con demanda uniforme) y coincide con el lote óptimo teórico de la pregunta 6.

Las políticas con $s \leq 6$ nunca garantizan el servicio. Si solo se mirara la ganancia, la mayor media de la hoja sería $s = 7$, $Q = 20$ con demanda uniforme (\$104.149.102; probabilidad de pérdida 0,0000) y $s = 5$, $Q = 15$ con la empírica (\$103.825.750; probabilidad de pérdida 0,0312). En Excel cada política usa números aleatorios distintos, así que el error estándar de la diferencia de dos medias es aproximadamente \$445.217, y solo diferencias mayores que \$890.434 (dos errores estándar) se distinguen del azar.

Costo del servicio completo. Bajar a $s = 6$ sí aumenta un poco la ganancia esperada: sobra menos inventario al 31/12 (cada unidad sobrante cuesta \$600.000) y una venta perdida solo cuesta el margen de \$80.000. Con 1000 réplicas y números aleatorios comunes (Parte B), la ganancia adicional de $s = 6$, $Q = 15$ frente a la recomendada es \$401.231 $\pm$ \$267.232 con demanda uniforme y \$421.108 $\pm$ \$219.755 con la empírica (diferencias significativa y significativa, del 0,39 % y 0,41 % de la ganancia), a cambio de días con faltante en una fracción de 0,0135 y 0,0066. La recomendación $s = 7$, $Q = 15$ paga ese costo pequeño para garantizar servicio completo; si la empresa aceptara faltantes ocasionales, $s = 6$, $Q = 15$ sería la alternativa.

2.5 | Pregunta 4: forma de los histogramas y origen de la variabilidad

Los histogramas de la Figura 2.1 son unimodales y aproximadamente simétricos, con forma de campana. La ganancia va de 97,47 a 111,43 millones (uniforme) y de 96,11 a 109,99 millones (empírica). Es una dispersión moderada: la desviación estándar es de unos \$3 millones sobre una media de \$103 millones.

La variabilidad entre réplicas se explica sobre todo por el **inventario final del 31/12/2026**. Por el supuesto 10, ese inventario no tiene valor residual: cada unidad sobrante se pagó a \$600.000 y nunca se vende. El inventario de cierre depende de en qué punto del ciclo de pedidos termina el año. Si el último pedido de $Q = 15$ unidades llegó en los últimos días, sobran muchas unidades; si llegó semanas antes, sobran pocas. En las 100 réplicas de Excel varió entre 0–18 (uniforme) y 1–18 (empírica) unidades. La relación se midió en la hoja (celdas `AC30:AC33`):

Tabla 2.4: Regresión de la ganancia anual sobre el inventario sobrante al 31/12.

	Uniforme	Empírica
Inventario final promedio (unidades)	9,29	9,61
Correlación ganancia–inventario final	−0,815	−0,865
Pendiente ($ por unidad sobrante)	−$585.719	−$572.986
Variabilidad explicada (R^2)	66,5 %	74,9 %

La pendiente es del orden del costo unitario de $600.000: cada unidad que sobra al cierre resta aproximadamente su costo de compra. Esta sola variable explica el 66,5 % (uniforme) y el 74,9 % (empírica) de la variabilidad de la ganancia en Excel, y el 51,1 % y 74,1 % en Python (pendientes de −$493.530 y −$650.962 por unidad). El resto proviene del volumen total demandado en el año. Su desviación estándar es $\sqrt{313\,\mathrm{Var}[D]} \approx 25$ unidades (uniforme) y 22 (empírica), y cada unidad vendida deja un margen aproximado de $80.000 menos el costo de pedido prorrateado, es decir, cerca de $2 millones de desviación. La combinación de ambos efectos ($\sqrt{2^2 + 2{,}6^2} \approx 3{,}3$ millones, tomando el inventario de cierre como aproximadamente uniforme dentro de un ciclo de Q unidades) reproduce el orden de magnitud de la desviación estándar observada.

2.6 | Pregunta 5: $s \geq 7$ y $Q \geq 7$ implican cero ventas perdidas

Proposición. Si $s \geq 7$ y $Q \geq 7$, entonces $P_t = 0$ para todo $t = 1, \ldots, 313$ y toda secuencia de demandas $D_t \in \{3, \ldots, 7\}$.

Demostración. Basta probar que $II_t \geq 7$ para todo t. Como $D_t \leq 7$, eso da $V_t = \min(II_t, D_t) = D_t$ y por tanto $P_t = D_t - V_t = 0$.

- *Día 1:* por la ecuación (2), $II_1 = R_1 = Q \geq 7$.
- *Día $t \geq 2$:* hay dos casos según la revisión del día anterior (ecuación 4).
  - Si $IF_{t-1} \geq s$, no se pidió ($O_{t-1} = 0$) y $II_t = IF_{t-1} \geq s \geq 7$.
  - Si $IF_{t-1} < s$, se pidió ($O_{t-1} = 1$), el pedido llega al inicio del día t (tiempo de entrega cero) y $II_t = IF_{t-1} + Q \geq 0 + Q \geq 7$, porque $IF_{t-1} \geq 0$.

En ambos casos $II_t \geq 7 \geq D_t$. ■

Las dos condiciones son necesarias. Con $s \leq 6$ el día puede empezar con 6 unidades sin pedido pendiente, y una demanda de 7 genera faltante. Con $Q \leq 6$ un día que empieza con inventario final 0 más el pedido tiene solo $Q < 7$ unidades.

Confirmación con los resultados. En la hoja `Politicas` todas las políticas con $s \geq 7$ tienen probabilidad de ventas perdidas exactamente 0,0000, y todas las de $s \leq 6$ tienen faltantes (tabla 2.2). En Python, las 36 políticas de la rejilla con $s \geq 7$ y $Q \geq 7$ tienen cero ventas perdidas con ambas demandas, mientras que las de $s \leq 6$ siempre presentan faltantes.

2.7 | Pregunta 6: efecto de aumentar Q con s fijo

Tabla 2.5: Excel, $s = 7$ fijo: ganancia promedio y desviación estándar según Q.

	Ganancia promedio		Desviación estándar	
Q	Uniforme	Empírica	Uniforme	Empírica
10	\$103.142.580	\$102.845.421	\$2.850.778	\$2.168.174
15	\$102.985.919	\$102.872.550	\$3.147.848	\$3.148.471
20	\$104.149.102	\$103.232.336	\$4.360.111	\$3.875.958
30	\$99.256.794	\$101.183.328	\$5.497.943	\$5.518.996

Con s fijo, la ganancia promedio **primero aumenta y luego disminuye** al crecer Q, con un máximo plano alrededor de $Q \approx 13$–17. La desviación estándar crece de forma sostenida. En Excel la caída para lotes grandes es clara: con $Q = 30$ la ganancia es \$3.729.124 (uniforme) y \$1.689.223 (empírica) menor que con $Q = 15$, y la desviación estándar es 1,75 veces mayor. Entre $Q = 10$, 15 y 20 las diferencias son del orden del error de Montecarlo, porque cada política usa números aleatorios distintos. La forma completa de la curva se ve en la rejilla de Python con $s = 7$ y Q de 8 a 30 (tablas 3.3 y 3.4) y en la corrida de 1000 réplicas (tabla 3.6). Con $s \geq 7$ no hay ventas perdidas, así que los ingresos y los costos fijos no dependen de Q; la tendencia la explican tres costos:

- **Costo por pedido** (pesa más con Q pequeño): se hacen cerca de $1565/Q$ pedidos al año, con un costo de $40{,}000 \times 1565/Q$. Ese costo baja de \$6,3 millones con $Q = 10$ a \$4,2 millones con $Q = 15$ y \$3,1 millones con $Q = 20$.
- **Inventario sobrante al 31/12** (pesa más con Q grande): en promedio sobran unas $Q/2$ unidades adicionales a \$600.000 cada una, es decir, unos \$300.000 por cada unidad adicional de Q. También aumenta el riesgo, porque el sobrante puede llegar a $s - 1 + Q$ unidades.
- **Almacenamiento:** \$80 por unidad-día equivale a unos \$25.000 por unidad de inventario promedio al año. Es casi despreciable frente a los dos anteriores.

Minimizar $C(Q) = 40{,}000 \cdot \frac{1565}{Q} + (600{,}000 + 25{,}040) \cdot \frac{Q}{2}$ da $Q^* = \sqrt{2 \cdot 40{,}000 \cdot 1565/625{,}040} \approx 14{,}2$ unidades. Este razonamiento, análogo al lote económico [4], coincide con el máximo observado en la simulación y respalda $Q = 15$.

3 | Parte B: análisis del modelo en Python

El programa reproduce la Parte A con bucles explícitos: cada línea de `simulate_year` corresponde a una columna de la hoja. Se verifica automáticamente con el ejemplo del enunciado (tabla 1.1) y con el calendario de 313 días. Ejecutar el programa completo (casi 34.000 años simulados) tomó 10,8 segundos.

3.1 | Pregunta 1: estadísticos, histogramas y comparación con Excel

Tabla 3.1: Política $s = 7$, $Q = 15$: Python (semilla 1000337497) frente a Excel, 100 réplicas cada uno.

	Demanda uniforme		Demanda empírica	
Estadístico	Python	Excel	Python	Excel
Ganancia promedio	\$103.449.494	\$102.985.919	\$102.842.986	\$102.872.550
Desviación estándar	\$3.251.964	\$3.147.848	\$3.714.339	\$3.148.471
Error estándar de la media	\$325.196	\$314.785	\$371.434	\$314.847
Prob. de ventas perdidas	0,0000	0,0000	0,0000	0,0000
Ventas perdidas por día	0,0000	0,0000	0,0000	0,0000
Diferencia Excel − Python	−\$463.576 ($z = -1{,}02$)		\$29.564 ($z = 0{,}06$)	

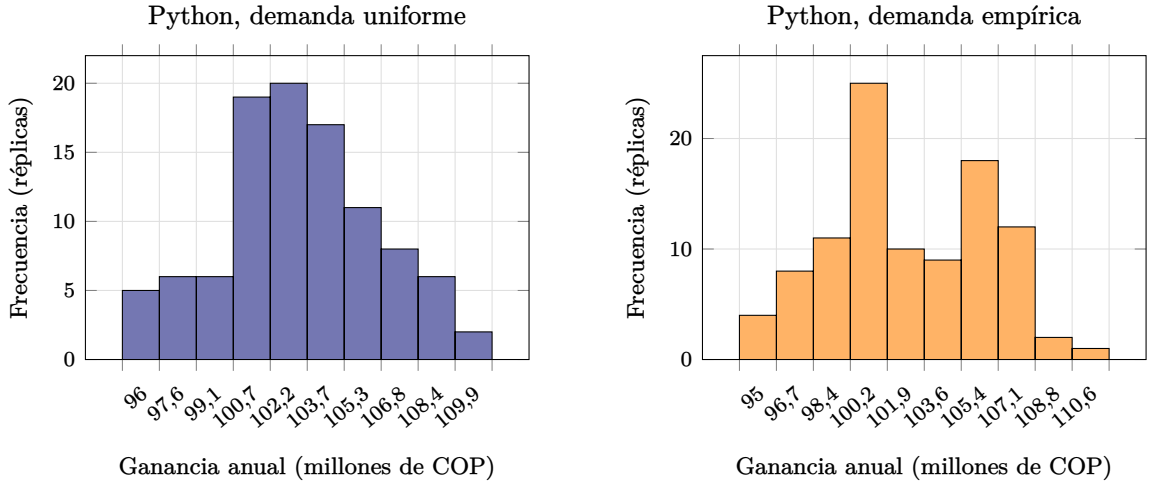


Figura 3.1: Histogramas de la ganancia anual en Python (`bins=10`, mismas clases de igual ancho que en Excel). El programa los guarda como `hist_uniforme.png` y `hist_empirica.png`.

¿Son iguales? ¿Deberían serlo? No son iguales y **no deberían serlo**. La lógica del modelo es idéntica: con las mismas demandas ambas herramientas dan exactamente las mismas utilidades, como muestra el ejemplo de verificación. Pero cada herramienta genera números aleatorios distintos (`ALEATORIO()` en la hoja de cálculo y el generador PCG64 de NumPy con semilla 1000337497 en Python). Por eso cada una obtiene una muestra diferente de 100 años.

Lo que sí debe ocurrir es que las diferencias sean explicables por el azar. Para dos muestras independientes, $z = (\bar{G}_{\text{Excel}} - \bar{G}_{\text{Python}})/\sqrt{EE_1^2 + EE_2^2}$ vale $-1{,}02$ y $0{,}06$, ambos con $|z| < 1{,}96$: las diferencias no son significativas al 5 %; las medias difieren menos del 1 %. Las desviaciones estándar son del mismo orden (unos \$3 millones), las dos herramientas dan cero ventas perdidas y los histogramas tienen la misma forma.

3.2 | Pregunta 2: sensibilidad a la semilla

Tabla 3.2: Ganancia promedio de 100 réplicas con cinco semillas distintas ($s = 7$, $Q = 15$).

Semilla	Uniforme	Empírica
1000337497	\$103.449.494	\$102.842.986
2026	\$103.322.879	\$102.829.427
42	\$103.332.046	\$103.092.180
777	\$103.206.162	\$103.835.812
31415	\$103.582.958	\$102.742.836
Rango (máx. − mín.)	\$376.796 (0,36 %)	\$1.092.976 (1,06 %)
Desv. estándar entre semillas	\$142.999	\$448.162
Error estándar teórico ($S_G/\sqrt{100}$)	\$325.196	\$371.434

La ganancia promedio cambia entre \$376.796 (uniforme) y \$1.092.976 (empírica) de una semilla a otra, como máximo el 1,06 % de la media. La desviación estándar entre las cinco medias es del mismo orden que el error estándar teórico $S_G/\sqrt{n} \approx$ \$0,3 millones, como predice la teoría: la media de 100 réplicas es una variable aleatoria con esa dispersión.

Implicación sobre la precisión. Con 100 réplicas, la ganancia esperada se conoce con un intervalo de confianza del 95 % de unos ±\$0,6 millones (por ejemplo, [\$102.804.240; \$104.094.749] para la uniforme). Es suficiente para afirmar que la ganancia anual es de unos \$103 millones, pero **no** para distinguir políticas cuyas medias difieren en \$0,1–0,5 millones, como las mejores de la rejilla. El error disminuye como $1/\sqrt{n}$ [1]: para reducirlo a la mitad hacen falta 4 veces más réplicas. Por eso la Parte B usa además números aleatorios comunes y una corrida de 1000 réplicas (intervalos de ±\$205.072).

3.3 | Pregunta 3: rejilla amplia de políticas

Se evaluaron 72 políticas ($s \in \{4, \ldots, 9\}$ y $Q \in \{8, 10, 12, \ldots, 18, 20, 25, 30\}$) con números aleatorios comunes, 100 réplicas y semilla 1000337497. Es una rejilla ocho veces más amplia que la de Excel (9 políticas). Las tablas 3.3 y 3.4 muestran la ganancia promedio en millones de pesos (negrita: máximo sin restricción; sombreado: política recomendada). La tabla 3.5 muestra la probabilidad de ventas perdidas.

Tabla 3.3: Python, demanda uniforme: ganancia promedio (millones de COP) por (s, Q).

$s \backslash Q$	8	10	12	13	14	15	16	17	18	20	25	30
4	97,48	99,70	100,89	101,28	101,32	101,69	102,01	102,09	102,34	101,45	101,24	99,67
5	100,36	101,77	102,36	103,01	102,87	102,99	103,43	102,79	102,62	102,84	**103,45**	102,45
6	101,84	102,78	103,37	103,23	103,18	103,27	103,40	103,20	102,91	103,01	101,22	101,50
7	101,58	102,81	103,13	103,38	103,11	103,45	103,33	103,33	102,77	103,17	101,36	100,85
8	101,02	102,18	102,60	102,57	102,33	102,79	102,72	102,90	102,64	102,42	101,04	99,74
9	100,46	101,19	101,77	102,07	101,54	101,77	102,12	101,95	101,86	101,68	100,41	98,45

Tabla 3.4: Python, demanda empírica: ganancia promedio (millones de COP) por (s, Q).

$s \backslash Q$	8	10	12	13	14	15	16	17	18	20	25	30
4	98,60	100,03	101,69	101,82	101,78	102,02	102,36	102,85	101,83	101,91	102,18	100,25
5	101,29	102,45	103,33	103,25	103,47	103,10	103,86	102,81	103,47	103,45	102,42	101,84
6	102,06	102,98	103,83	**104,04**	103,22	103,73	103,48	103,32	103,44	102,88	102,25	101,59
7	101,48	102,47	102,43	102,98	103,16	102,84	102,75	102,90	102,73	102,48	101,60	100,51
8	101,07	101,90	102,11	102,17	102,89	102,28	102,34	102,47	102,27	101,85	100,82	99,77
9	100,27	101,45	101,44	101,36	102,52	101,44	101,73	101,52	101,27	101,46	100,34	99,02

Tabla 3.5: Python: probabilidad de ventas perdidas por (s, Q) (uniforme arriba, empírica abajo).

$s \backslash Q$	8	10	12	13	14	15	16	17	18	20	25	30
4	0,144	0,120	0,093	0,084	0,082	0,080	0,073	0,069	0,064	0,058	0,046	0,039
5	0,077	0,058	0,053	0,043	0,042	0,038	0,039	0,035	0,034	0,028	0,023	0,019
6	0,025	0,019	0,016	0,016	0,014	0,014	0,012	0,011	0,011	0,010	0,007	0,006
7	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000
8	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000
9	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000
4	0,139	0,130	0,091	0,086	0,086	0,081	0,073	0,066	0,064	0,061	0,046	0,039
5	0,058	0,048	0,034	0,034	0,031	0,029	0,028	0,025	0,024	0,022	0,018	0,015
6	0,013	0,010	0,009	0,007	0,007	0,007	0,006	0,006	0,006	0,006	0,003	0,004
7	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000
8	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000
9	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000

¿Coincide con Excel? Por ganancia pura, la mejor política de la rejilla es $s = 5$, $Q = 25$ con demanda uniforme ($103.454.082) y $s = 6$, $Q = 13$ con la empírica ($104.037.003). Las dos tienen $s \leq 6$ y pierden ventas (probabilidad 0,0230 y 0,0073), así que no cumplen el criterio de servicio. Su ventaja sobre la política recomendada, medida con diferencias pareadas, es $4.587 ± $1.023.294 (no significativa) y $1.194.017 ± $734.001 (significativa; IC del 95 %). Es el mismo efecto que mide la corrida de 1000 réplicas de la Parte A (pregunta 3): un s menor gana algo más porque deja menos inventario sin valor al 31/12, pero pierde ventas.

Con el mismo criterio de la Parte A (cero ventas perdidas y máxima ganancia promedio conjunta), la rejilla de 100 réplicas elige $s = 7$, $Q = 13$. Esta política difiere de la recomendada solo en Q, y por una cantidad que no es significativa (−$70.372 ± $603.284 y $139.142 ± $673.635). Para resolver el empate se repitieron las políticas con $s = 7$ y $Q = 11, \ldots, 19$ con 1000 réplicas y números aleatorios comunes (tabla 3.6).

Tabla 3.6: $s = 7$ con 1000 réplicas: ganancia promedio y diferencia pareada frente a $Q = 15$ (IC del 95 %).

	Demanda uniforme		Demanda empírica	
Q	Media	Dif. vs. $Q = 15$	Media	Dif. vs. $Q = 15$
11	$102.926.194	−$345.380 ± $202.536	$103.142.073	−$192.113 ± $203.163
12	$103.104.975	−$166.599 ± $199.233	$103.361.303	$27.116 ± $201.304
13	$103.263.648	−$7.925 ± $191.730	$103.361.276	$27.090 ± $184.208
14	$103.409.558	$137.984 ± $265.725	$103.490.922	$156.735 ± $268.999
15	$103.271.573	–	$103.334.186	–
16	$103.375.177	$103.604 ± $285.331	$103.397.419	$63.233 ± $287.115
17	$103.078.979	−$192.594 ± $256.006	$103.250.927	−$83.260 ± $258.894
18	$103.046.891	−$224.682 ± $265.501	$103.114.934	−$219.252 ± $276.858
19	$102.933.175	−$338.398 ± $258.621	$102.977.296	−$356.890 ± $257.211

Con mayor precisión se confirma una meseta: ningún valor de Q supera significativamente a $Q = 15$. Las medias bajan hacia los extremos, y la caída ya es significativa en $Q \in \{11, 19\}$

(uniforme) y $Q \in \{19\}$ (empírica). Esto coincide con el análisis de costos de la pregunta 6 de la Parte A ($Q^* \approx 14$). Por lo tanto, entre las políticas con servicio completo, **la mejor coincide con la elegida en Excel**: $s = 7$, $Q = 15$. Es el menor s que garantiza servicio completo y un Q en el centro de la meseta óptima. Las diferencias de orden en la rejilla de 100 réplicas (la recomendada queda en el puesto 2 con demanda uniforme y 22 con la empírica) se deben al ruido de Montecarlo y no a diferencias reales.

3.4 | Pregunta 4: ¿por qué la misma semilla para todas las políticas?

`compare_policies` crea el generador con la misma semilla para cada política (*números aleatorios comunes* [1, 2]). Así, todas las políticas enfrentan exactamente las mismas 100 secuencias de 313 demandas, y la diferencia de ganancia entre dos políticas se debe solo a la política, no a que una tuvo por suerte un año de demanda más alta. Estadísticamente,

$$\mathrm{Var}(\bar{G}_A - \bar{G}_B) = \mathrm{Var}(\bar{G}_A) + \mathrm{Var}(\bar{G}_B) - 2\,\mathrm{Cov}(\bar{G}_A, \bar{G}_B),$$

y con números comunes la covarianza es positiva (años de alta demanda favorecen a ambas políticas), lo que reduce la varianza de la diferencia.

¿Qué pasaría sin ellos? Las diferencias mezclarían el efecto de la política con el ruido del muestreo, y el ranking podría invertirse por azar. Por ejemplo, al comparar la mejor política sin restricción con la recomendada usando corrientes aleatorias independientes, el intervalo de la diferencia fue ±\$1.134.070 (uniforme) y ±\$844.382 (empírica), frente a ±\$1.023.294 y ±\$734.001 con números comunes. La diferencia estimada también cambió (\$107.550 y \$504.703, frente a \$4.587 y \$1.194.017). Con 72 políticas evaluadas de forma independiente, la que parezca mejor sería, en buena medida, la que tuvo más suerte. Los números comunes no eliminan el error de Montecarlo, pero hacen la comparación justa y más precisa con el mismo número de réplicas.

3.5 | Pregunta 5: Excel frente a Python

Tabla 3.7: Comparación de las dos herramientas para este modelo.

Criterio	Excel	Python
Tiempo de cómputo	La tabla de datos recalcula el libro completo (2 hojas de 313 filas y 18 columnas) una vez por réplica: 100 recálculos por cada F9. El libro se vuelve lento, por eso se usa el modo "automático excepto en las tablas de datos".	El programa completo (unos 34.000 años simulados: estadísticos, 5 semillas, 72 políticas × 2 demandas y la corrida de 1000 réplicas) tarda 10,8 s.
Cambiar réplicas o políticas	Más réplicas exige ampliar la tabla de datos y los rangos de las fórmulas. Cada política exige cambiar s y Q a mano, recalcular y copiar valores (9 políticas = 9 ciclos manuales).	Se cambia `N_REPLICATIONS` o la lista `POLICIES` en una línea. Pasar de 9 a 72 políticas no requiere trabajo adicional.
Trazabilidad	Excelente para ver un año: cada día y cada costo están en una celda visible y auditable. Pero las réplicas de la tabla de datos no se pueden reproducir: `ALEATORIO()` no tiene semilla y cambia con cada F9.	Cada resultado se puede reproducir exactamente gracias a la semilla. El flujo (calendario → demanda → simulación → estadísticos) es explícito y puede imprimir el registro diario (`keep_log=True`).
Riesgo de errores	Referencias mal copiadas, rangos que no cubren las 313 filas, celda de entrada de la tabla de datos mal elegida, valores pegados que quedan desactualizados.	Errores de lógica (índices, orden de eventos). Se mitigan con funciones pequeñas, la prueba obligatoria automática (`check_statement_example`) y la verificación del calendario.
Comparación de políticas	Sin números aleatorios comunes: cada política usa números distintos, lo que añade ruido.	Números aleatorios comunes, intervalos pareados y miles de réplicas sin esfuerzo adicional.

En síntesis, Excel es ideal para construir, explicar y auditar la lógica de un año. Python es superior para la experimentación: muchas réplicas y políticas, resultados reproducibles y comparaciones estadísticamente rigurosas. Validar un modelo contra el otro, con el ejemplo de verificación y con estadísticos comparables, aumenta la confianza en ambos.

4 | Conclusiones

1. Los dos modelos implementan las mismas ecuaciones y reproducen exactamente el ejemplo de verificación del enunciado.
2. Se recomienda la política $\boldsymbol{s = 7,\ Q = 15}$. Garantiza cero ventas perdidas con cualquier secuencia de demandas (demostrado en la pregunta 5 y confirmado en las simulaciones), y entre las políticas con servicio completo su ganancia, de unos \$103 millones al año, es estadísticamente equivalente a la mejor de una rejilla de 72 políticas. Las políticas con $s = 6$ ganan cerca de \$421.108 más al año (alrededor del 0,4 %) a costa de perder ventas.
3. La variabilidad de la ganancia anual (desviación estándar de unos \$3 millones) se debe sobre todo al inventario sin valor residual que queda al 31 de diciembre, y en segundo lugar

al volumen total de demanda del año.

4. Las dos distribuciones de demanda tienen la misma media (5) y producen ganancias promedio similares. La empírica, con menor varianza (1,5 frente a 2), genera menos ventas perdidas cuando $s < 7$.

5. Con 100 réplicas la ganancia esperada se estima con un margen de unos ±\$0,6 millones (95 %). Para comparar políticas cercanas se necesitan números aleatorios comunes y más réplicas.

5 | Referencias

[1] Averill M. Law. *Simulation Modeling and Analysis.* McGraw-Hill Education, New York, 2015. 5.ª edición.

[2] Sheldon M. Ross. *Simulation.* Academic Press, San Diego, 2013. 5.ª edición.

[3] Universidad EAFIT. Taller 2: Simulación Montecarlo de un sistema de inventarios. Métodos Cuantitativos, enunciado del taller, 2026.

[4] Wayne L. Winston. *Investigación de operaciones: aplicaciones y algoritmos.* Thomson, México, 2004. 4.ª edición.